

Udemy - 3 - Modeling Lab - CNN on EC2

Create an EC2 using an AMI with deep learning




We will use a p2.2xl





Select a key pair





Make sure we can connect Go to Security group and allow our IP





Now connect



We want to use a Jupyter notebook and tunnel through it

Copy the Public DNS

To access your instance:

- Open an SSH client. (find out how to connect using PuTTY)
- Locate your private key file (SundogEC2.pem). The wizard automatically detects the key you us to launch the instance.
- 3. Your key must not be publicly viewable for SSH to work. Use this command if needed:

chmod 400 SundogEC2.pem


Connect to your instance using its Pub\(\tilde{\textbf{h}}\)c DNS:

```
ec2-3-92-23-228.compute-1.amazonaws.com
```

Example:


ssh -i "SundogEC2.pem" ubuntu@ec2-3-92-23-228.compute-1.amazonaws.com


Set up tunnel





Now we are on the instance





Copy the url and paste into browser


```
№ ubuntu@ip-172-30-0-27: ~

                                                                         \times
  17:22:27.898 NotebookApp] 0 active kernels
  17:22:27.898 NotebookApp] The Jupyter Notebook is running at:
  17:22:27.898 NotebookApp] http://localhost:8888/?token=483d252f18833a91b827bc
9175ed047fa3d41b04e0d4fd7
 17:22:27.898 NotebookApp] Use Control-C to stop this server and shut down all
kernels (twice to skip confirmation).
W 17:22:27.899 NotebookApp] No web browser found: could not locate runnable bro
ser.
17:22:27.899 NotebookApp]
   Copy/paste this URL into your browser when you connect for the first time,
   to login with a token:
       http://localhost:$888/?token=483d252f18833a91b827bc39175ed047fa3d41b04e0
4fd7&token=483d252f18833a91b827bc39175ed047fa3d41b04e0d4fd7
```

Now connected to EC2 via a tunnel.




Upload notebook



Use tensorflow kernel:





Load the data

Transform the data: reshape 1 dimensional pixel data into 2 dimensional arrays of 28x28 pixels

Also need to scale the data down (/ 255)

Since we're treating the data as 2D images of 28x28 pixels, we need to shape it accordingly. Depending on the data format Keras is set up for, this may be 1x28x28 or 28x28x1 (the "1" indicates a single color channel, as this is just grayscale. If we were dealing with color images, it would be 3 instead of 1 since we'd have red, green, and blue color channels)

```
In [3]: from tensorflow.keras import backend as K

if K.image_data_format() == 'channels_first':
    train_images = mnist_train_images.reshape(mnist_train_images.shape[0], 1, 28, 28)
    test_images = mnist_test_images.reshape(mnist_test_images.shape[0], 1, 28, 28)
    input_shape = (1, 28, 28)
else:
    train_images = mnist_train_images.reshape(mnist_train_images.shape[0], 28, 28, 1)
    test_images = mnist_test_images.reshape(mnist_test_images.shape[0], 28, 28, 1)
    input_shape = (28, 28, 1)


train_images = train_images.astype('float32')
    test_images = test_images.astype('float32')
    train_images /= 255
    test_images /= 255
```

Convert data with One-hot encoding

We need to convert our train and test labels to be categorical in one-hot format:

```
In [4]: train_labels = tensorflow.keras.utils.to_categorical(mnist_train_labels, 10)|
test_labels = tensorflow.keras.utils.to_categorical(mnist_test_labels, 10)
```

As a sanity check let's print out one of the training images with its label:



Now for the meat of the problem. Setting up a convolutional neural network involves more layers.

We'll start with a 2D convolution of the image - it's set up to take 32 windows, or "filters", of each image, each filter being 3x3 in size.

We then run a second convolution on top of that with 64 3x3 windows - this topology is just what comes recommended within Keras's own examples. Again you want to re-use previous research whenever possible while tuning CNN's, as it is hard to do.

Next we apply a MaxPooling2D layer that takes the maximum of each 2x2 result to distill the results down into something more manageable.

Next we flatten the 2D layer we have at this stage into a 1D layer. So at this point we can just pretend we have a traditional multi-layer perceptron...

... and feed that into a hidden, flat layer of 128 units.

And finally, we feed that into our final 10 units where softmax is applied to choose our category of 0-9.

```
In [7]: model.summary()
         Model: "sequential"
         Layer (type)
                                           Output Shape
         conv2d (Conv2D)
                                           (None, 26, 26, 32)
                                                                         320
         conv2d 1 (Conv2D)
                                           (None, 24, 24, 64)
                                                                         18496
         max_pooling2d (MaxPooling2D) (None, 12, 12, 64)
         flatten (Flatten)
                                           (None, 9216)
                                                                         0
         dense (Dense)
                                           (None, 128)
                                                                         1179776
         dense_1 (Dense)
                                           (None, 10)
                                                                         1290
          Total params: 1,199,882
         Trainable params: 1,199,882
Non-trainable params: 0
         We are doing multiple categorization, so categorical crossentropy is still the right loss function to use. We'll use the Adam optimizer, although the example
         provided with Keras uses RMSProp. You might want to try both if you have time.
In [8]: model.compile(loss='categorical_crossentropy',
                         optimizer='adam',
metrics=['accuracy'])
                                                                       Ι
```

Now we can train the model

Warning

This will take a few minutes to run on a p3.large instance.

Accuracy on training data after epoch 3 its increasing quicker than with validation set

Sign we are over-fitting

=> Use Dropout layers to regularize.

So, you can see that we started overfitting pretty early on, as our accuracy on the test set started exceeding our accuracy on the validation set. Our validation accuracy maxed out at around 99.0% after just a couple of epochs, while our accuracy on the test set kept climbing.

To prevent overfitting, we need to perform some sort of regularization. Dropout layers are one such technique in deep learning; they work by "dropping out" neurons on each pass to force learning to spread itself out across the network as a whole.

Now results are better

Let's run it again with those two dropout layers added in.

```
In [11]: model.compile(loss='categorical_crossentropy',
                         optimizer='adam',
metrics=['accuracy'])
In [12]: history = model.fit(train_images, train_labels,
                               batch_size=32,
epochs=10,
                                verbose=2
                               validation_data=(test_images, test_labels))
          Train on 60000 samples, validate on 10000 samples
          Epoch 1/10
60000/60000 - 14s - loss: 0.1909 - acc: 0.9413 - val_loss: 0.0449 - val_acc: 0.9854
          Epoch 2/10
          60000/60000 - 13s - loss: 0.0791 - acc: 0.9758 - val_loss: 0.0300 - val_acc: 0.9902
          Epoch 3/10
          60000/60000 - 13s - loss: 0.0620 - acc: 0.9808 - val_loss: 0.0356 - val_acc: 0.9883
          Epoch 4/10
          60000/60000 - 13s - loss: 0.0511 - acc: 0.9845 - val_loss: 0.0288 - val_acc: 0.9914
          Epoch 5/10
          60000/60000 - 13s - loss: 0.0429 - acc: 0.9869 - val_loss: 0.0270 - val_acc: 0.9917
          Epoch 6/10
          60000/60000 - 13s - loss: 0.0356 - acc: 0.9890 - val_loss: 0.0266 - val_acc: 0.9918
          60000/60000 - 13s - loss: 0.0331 - acc: 0.9890 - val_loss: 0.0279 - val_acc: 0.9923
          Epoch 8/10
          60000/60000 - 13s - loss: 0.0300 - acc: 0.9902 - val_loss: 0.0270 - val_acc: 0.9927
          Epoch 9/10
          60000/60000 - 13s - loss: 0.0266 - acc: 0.9913 - val_loss: 0.0303 - val_acc: 0.9920
          Epoch 10/10
          60000/60000 - 13s - loss: 0.0261 - acc: 0.9914 - val_loss: 0.0289 - val_acc: 0.9923
                                                           -12
           That's better; our train and test accuracy ended up about the same, at 99.2%. There may still be a tiny bit of overfitting going on, but it's a lot better.
           Let's also explore the effect the batch size has; as an experiment, let's increase it up to 1000.
```

Let's now explore batch size of 1000 instead of 32

```
In [13]: model = MakeModel()
                             model.compile(loss='categorical_crossentropy',
                                                                 optimizer='adam'
                                                                 metrics=['accuracy'])
                            history = model.fit(train_images, train_labels,
                                                                                  batch_size=1000,
                                                                                  epochs=10,
                                                                                   verbose=2,
                                                                                 validation data=(test images, test labels))
                             Train on 60000 samples, validate on 10000 samples
                            Epoch 1/10 60000/60000 - 6s - loss: 0.5625 - acc: 0.8303 - val_loss: 0.1380 - val_acc: 0.9585
                            Epoch 2/10
                             60000/60000 - 5s - loss: 0.1605 - acc: 0.9540 - val_loss: 0.0676 - val_acc: 0.9799
                            Epoch 3/10
60000/60000 - 5s - loss: 0.1009 - acc: 0.9707 - val_loss: 0.0480 - val_acc: 0.9848
                             Epoch 4/10
                             60000/60000 - 5s - loss: 0.0779 - acc: 0.9770 - val_loss: 0.0417 - val_acc: 0.9859
                            Epoch 5/10
                            60000/60000 - 5s - loss: 0.0667 - acc: 0.9801 - val_loss: 0.0382 - val_acc: 0.9869
                            60000/60000 - 5s - loss: 0.0568 - acc: 0.9829 - val_loss: 0.0323 - val_acc: 0.9885
                            Epoch 7/10
                            60000/60000 - 5s - loss: 0.0497 - acc: 0.9848 - val_loss: 0.0302 - val_acc: 0.9899
                            Epoch 8/10
                             60000/60000 - 5s - loss: 0.0457 - acc: 0.9861 - val_loss: 0.0300 - val_acc: 0.9894
                            Epoch 9/10
                            60000/60000 - 5s - loss: 0.0397 - acc: 0.9876 - val_loss: 0.0296 - val_acc: 0.9897
click to scroll output; double click to hide
ত্ত্তত্ত্বেত ত ১৮ ০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০ - ১৮ ০০০০০ - ১৮ ০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০০ - ১৮ ০০০০ - ১৮ ০০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১৮ ০০০০ - ১০০০ - ১০০০ - ১০০০ - ১০০০ - ১০০০ - ১০০০ - ১০০০ - ১০০০ - ১
```

Results are not as good

Pb of too large batch size -> can get stuck in local minima

If you run this block a few times, you'll probably get very different results. Large batch sizes tend to get stuck in "local minima", and converge on the wrong solution at random. Smaller batch sizes also have a regularization effect. Sometimes you'll get lucky and the large batch will converge on a good solution; other times, not so much.

Now let's explroe learning rate impact buy increasing it

Let's explore the effect of the learning rate. The default learning rate for Adam is 0.001; let's see what happens if we increase it by an order of magnitude to 0.01:

Results are bad

```
In [15]: history = model.fit(train_images, train_labels,
                              batch_size=32,
                              epochs=10.
                              validation_data=(test_images, test_labels))
          Train on 60000 samples, validate on 10000 samples
          Epoch 1/10
          60000/60000 - 14s - loss: 0.2704 - acc: 0.9195 - val_loss: 0.0812 - val_acc: 0.9757
         Epoch 2/10
60000/60000 - 13s - loss: 0.1964 - acc: 0.9443 - val_loss: 0.0779 - val_acc: 0.9768
          Epoch 3/10
          60000/60000 - 13s - loss: 0.1840 - acc: 0.9493 - val_loss: 0.0679 - val_acc: 0.9801
          60000/60000 - 13s - loss: 0.1837 - acc: 0.9490 - val_loss: 0.0923 - val_acc: 0.9772
          60000/60000 - 13s - loss: 0.1781 - acc: 0.9524 - val_loss: 0.0695 - val_acc: 0.9797
          Epoch 6/10
          60000/60000 - 13s - loss: 0.1794 - acc: 0.9523 - val_loss: 0.0923 - val_acc: 0.9786
          Epoch 7/10
          60000/60000 - 13s - loss: 0.1821 - acc: 0.9521 - val_loss: 0.0743 - val_acc: 0.9774
          Epoch 8/10
          60000/60000 - 13s - loss: 0.1673 - acc: 0.9562 - val_loss: 0.0723 - val_acc: 0.9797
                                                                                                             10
          Epoch 9/10
          60000/60000 - 13s - loss: 0.1755 - acc: 0.9542 - val_loss: 0.0757 - val_acc: 0.9804
          Epoch 10/10
          60000/60000 - 14s - loss: 0.1773 - acc: 0.9540 - val_loss: 0.0892 - val_acc: 0.9804
         Yikesl That had a huge, and terrible, effect on the results. Small batch sizes are best paired with low learning rates, and large learning rates have a tendency to
```

Its because large learning rate has a tendency of over shooting correct minima

tune by just trying different values; we'll see more of that later in the course.

overshoot the correct solution entirely - which is probably what happened here. The learning rate is an example of a hyperparameter that you might want to